

Big Data Analysis of Student Performance

Université Chouaib Doukkali

Faculté des Sciences El Jadida

Module : Big Data

Réalisé par : Habiballah Aymane, Lazhari Adam, Msaiaid Hassan, Taha, Rihane Hamza

Encadré par : Pr. Nouhaila IDRISSE

Année universitaire : 2025 / 2026

Rapport de projet

1. Introduction

Ce rapport présente un projet Big Data réalisé autour du dataset StudentsPerformance.csv. Le but est d'analyser les performances des étudiants à travers un pipeline simple et cohérent : stockage dans HDFS, interrogation avec Hive, traitement complémentaire avec Spark, puis visualisation des résultats. Le rapport évite de répéter les mêmes tableaux : chaque résultat est présenté une seule fois, puis interprété de manière claire.

2. Problématique

Comment les technologies Big Data peuvent-elles aider à analyser les performances des étudiants et à identifier les facteurs qui influencent leurs résultats scolaires ?

3. Objectifs

- Stocker le fichier CSV dans HDFS.
- Créer une table externe Hive pointant vers les données HDFS.
- Extraire des indicateurs avec HiveQL.
- Réaliser une analyse complémentaire avec Spark / PySpark.
- Présenter les résultats sous forme de visualisations et d'interprétations.

3.1 Répartition des tâches dans l'équipe

Pour organiser le travail, chaque membre de l'équipe a pris en charge une partie précise du projet. Cette répartition nous a permis d'avancer de manière claire : Hive pour l'analyse SQL, Spark pour l'analyse distribuée, et la visualisation pour la présentation des résultats.

Tâche	Réalisée par	Description
Analyse avec Hive	Habiballah Aymane et Lazhari Adam	Création de la table Hive, exécution des requêtes HiveQL, interprétation des résultats Hive.
Analyse avec Spark / PySpark	Msaiaid Hassan et Taha	Lecture du dataset depuis HDFS, calcul des agrégations Spark, Top 10 des étudiants et résultats Spark.
Visualisation des résultats	Rihane Hamza	Création du tableau de bord et des graphiques permettant d'interpréter les résultats.

4. Outils utilisés

Les outils utilisés dans le projet sont : Docker Desktop, Hadoop HDFS, Apache Hive, Beeline, Apache Spark, PySpark, Python et Git/GitHub.

5. Dataset

Le dataset contient 1000 étudiants. Les informations disponibles décrivent le profil de l'étudiant et ses scores dans trois matières : mathématiques, lecture et écriture.

Colonne	Description
gender	Sexe de l'étudiant
race/ethnicity	Groupe de l'étudiant
parental level of education	Niveau d'éducation des parents
lunch	Type de repas
test preparation course	Préparation au test
math score	Score en mathématiques
reading score	Score en lecture
writing score	Score en écriture

6. Architecture du pipeline

Le projet suit l'architecture suivante :

- StudentsPerformance.csv
- Stockage dans HDFS
- Table externe Hive
- Requêtes HiveQL
- Analyse complémentaire Spark / PySpark
- Visualisations
- Rapport final

Schéma simplifié : CSV → HDFS → Hive → Spark → Résultats → Visualisation → Rapport

7. Stockage dans HDFS

La première étape technique a consisté à charger le fichier StudentsPerformance.csv dans HDFS. Cette étape permet à Hive et Spark de lire le même fichier depuis un emplacement commun dans l'environnement Big Data.

- Création du dossier HDFS de travail.
- Chargement du fichier CSV depuis le volume Docker.
- Vérification de l'existence du fichier dans HDFS.
- Lecture d'un aperçu du fichier pour confirmer que le stockage est correct.

8. Analyse avec Hive

Tâche réalisée par : Habiballah Aymane et Lazhari Adam.

Hive a été utilisé pour créer une table externe qui pointe vers le fichier stocké dans HDFS. Cette table ne duplique pas les données : elle permet seulement de les interroger avec HiveQL. OpenCSVSerde a été utilisé pour lire correctement le format CSV.

8.1 Vérification de la table Hive

Cette capture montre que Hive lit correctement les premières lignes du dataset. Elle sert de preuve que la table externe pointe vers le bon emplacement HDFS.

students.gender	students.race_ethnicity	students.parental_level_of_education	students.lunch	students.test_preparation_course	students.math_score	student
female	group B	bachelor's degree	standard	none	72	72
female	group C	some college	standard	completed	69	90
female	group B	master's degree	standard	none	90	95
male	group A	associate's degree	free/reduced	none	47	57
male	group C	some college	standard	none	76	78
female	group B	associate's degree	standard	none	71	83
female	group B	some college	standard	completed	88	95
male	group B	some college	free/reduced	none	40	43
male	group D	high school	free/reduced	completed	64	64
female	group B	high school	free/reduced	none	38	60

Figure 1 : Aperçu des données lues par Hive.

8.2 Résumé des principaux résultats Hive

Pour éviter la redondance, les résultats Hive importants sont regroupés dans un seul tableau de synthèse.

Indicateur	Résultat
Nombre total d'étudiants	1000
Pass	897
Fail	103
Moyenne writing score	68.05
Moyenne reading score	69.17
Moyenne math score	66.09
Moyenne générale avec test preparation completed	72.67
Moyenne générale sans test preparation	65.04
Scores maximums	100 en math, reading et writing
Scores minimums	0 en math, 17 en reading, 10 en writing

result	total_students
Fail	103
Pass	897

Figure 2 : Résultat Pass / Fail obtenu avec Hive.

max_math	min_math	max_reading	min_reading	max_writing	min_writing
100	0	100	17	100	10

Figure 3 : Scores maximums et minimums avec Hive.

```
INFO : Completed executing command(queryId=hive_2020
```

test_preparation_course	avg_general_score
completed	72.66945996275605
none	65.03894080996888

Figure 4 : Impact du test preparation course avec Hive.

Interprétation : la majorité des étudiants réussissent selon le seuil choisi. La préparation au test améliore clairement la moyenne générale, ce qui constitue l'un des résultats les plus importants du projet.

9. Analyse avec Spark / PySpark

Tâche réalisée par : Msaiaid Hassan et Taha.

Spark a été utilisé pour compléter l'analyse Hive. Le script PySpark lit le fichier depuis HDFS, calcule des moyennes par genre, par préparation au test et par groupe, puis extrait les meilleurs étudiants selon le total des trois scores.

9.1 Résultat Spark : moyenne par genre

La capture Spark montre une différence intéressante : les femmes obtiennent de meilleurs résultats en lecture et écriture, tandis que les hommes ont une moyenne supérieure en mathématiques.

```
>>> from pyspark.sql.functions import avg
>>> df.groupBy("gender").agg(avg("math score").alias("avg_math"),avg("reading score").alias("avg_reading"),avg("writing score").alias("avg_writing") ).show()
```

gender	avg_math	avg_reading	avg_writing
female	63.633204633204635	72.60810810810811	72.46718146718146
male	68.72821576763485	65.47302984564316	63.31120331950208

Figure 5 : Moyennes par genre dans Spark.

9.2 Résultat Spark : Top 10

Le Top 10 a été obtenu après création d'une colonne total_score, correspondant à la somme des trois scores. Les meilleurs étudiants atteignent jusqu'à 300 points, ce qui correspond à des résultats parfaits.

```
>>> top10 = df2.orderBy( col("total_score").desc() ).limit(10)
>>> top1.show()
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'top1' is not defined
>>> top10.show()
```

gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score	total_score
female	group E	bachelor's degree	standard	none	100	100	100	300
male	group E	bachelor's degree	standard	completed	100	100	100	300
female	group E	associate's degree	standard	none	100	100	100	300
female	group E	bachelor's degree	standard	completed	99	100	100	299
female	group D	some high school	standard	completed	97	100	100	297
female	group D	some college	standard	none	98	100	99	297
female	group C	bachelor's degree	standard	completed	96	100	100	296
male	group D	some college	standard	completed	100	97	99	296
male	group E	associate's degree	free/reduced	completed	100	100	93	293
female	group E	master's degree	standard	completed	94	99	100	293

Figure 6 : Top 10 des étudiants selon Spark.

10. Visualisation et interprétation

Tâche réalisée par : Rihane Hamza.

La visualisation ci-dessous synthétise les résultats importants dans un tableau de bord unique. Elle permet de lire rapidement les tendances sans multiplier les tableaux dans le rapport.



Figure 7 : Tableau de bord de visualisation des résultats.

10.1 Indicateurs globaux

Les trois moyennes globales sont proches : writing score = 68.05, reading score = 69.17, math score = 66.09. La lecture présente la meilleure moyenne globale, suivie de l'écriture puis des mathématiques.

10.2 Status par gender

Le graphique Status par gender montre une majorité d'étudiants en réussite dans les deux groupes. Chez les femmes, on observe 479 réussites et 39 échecs. Chez les hommes, on observe 418 réussites et 64 échecs. La réussite est donc largement dominante, avec un avantage relatif pour les étudiantes.

10.3 Influence du lunch

Le graphique lié au lunch montre que les étudiants ayant un lunch standard obtiennent des moyennes plus élevées dans les trois matières que ceux ayant free/reduced lunch. Cela peut refléter un écart de contexte socio-économique, sans conclure à une causalité directe.

10.4 Influence du test preparation course

La préparation au test est l'un des facteurs les plus visibles : les étudiants ayant complété la préparation atteignent une moyenne générale d'environ 72.67, contre 65.04 pour ceux qui ne l'ont pas suivie. Cela confirme que la préparation améliore les performances globales.

10.5 Influence du parental level of education

Le graphique sur le niveau d'éducation des parents montre que les meilleurs résultats moyens sont associés à la catégorie master's degree. Les niveaux plus faibles, comme high school ou some high school, obtiennent des moyennes plus basses. Cela suggère qu'un environnement familial plus favorable sur le plan éducatif peut être lié à de meilleures performances.

11. Synthèse des résultats

- Le dataset contient 1000 étudiants.
- 897 étudiants sont classés Pass et 103 sont classés Fail.
- La préparation au test est associée à une meilleure moyenne générale.
- Les femmes ont de meilleures moyennes en lecture et écriture ; les hommes ont une moyenne plus élevée en mathématiques.
- Le groupe le plus performant selon la moyenne générale est group E.
- Le meilleur niveau d'éducation des parents observé est master's degree.
- Le dashboard confirme les tendances observées dans Hive et Spark sans répéter les mêmes tableaux.

12. Difficultés rencontrées

- Démarrage et stabilité de Docker Desktop.
- Différence entre chemins locaux, volumes Docker et chemins HDFS.
- Choix du bon LOCATION dans la table Hive.
- Lecture correcte du CSV avec OpenCSVSerde.
- Conversion des scores pour les calculs numériques dans Hive.
- Organisation des captures, résultats et visualisations sans créer de redondance.

13. Conclusion

Ce projet nous a permis de mettre en pratique un pipeline Big Data complet. HDFS a servi au stockage des données, Hive à l'analyse SQL, Spark à l'analyse distribuée complémentaire et la partie visualisation à présenter les résultats de manière claire. Les résultats montrent surtout l'effet positif de la préparation au test, la différence entre les matières selon le genre et l'influence possible du niveau d'éducation des parents. Le rapport final est organisé pour éviter la répétition : les tableaux essentiels sont regroupés, les captures servent de preuves, et les graphiques sont expliqués directement.

